Анализ данных маркетплейса Olist: от модели данных до витрины

Цель

Пройти полный путь работы с данными на реальном датасете: спроектировать реляционную модель, проверить качество данных и ответить на бизнес-вопрос: **как сроки доставки влияют на удовлетворённость клиентов**.

Данные

Brazilian E-Commerce Public Dataset by Olist (Kaggle): около 100 тыс. заказов бразильского маркетплейса за 2016–2018 годы, 8 связанных таблиц: заказы, позиции заказов, клиенты, товары, продавцы, платежи, отзывы, справочник категорий.

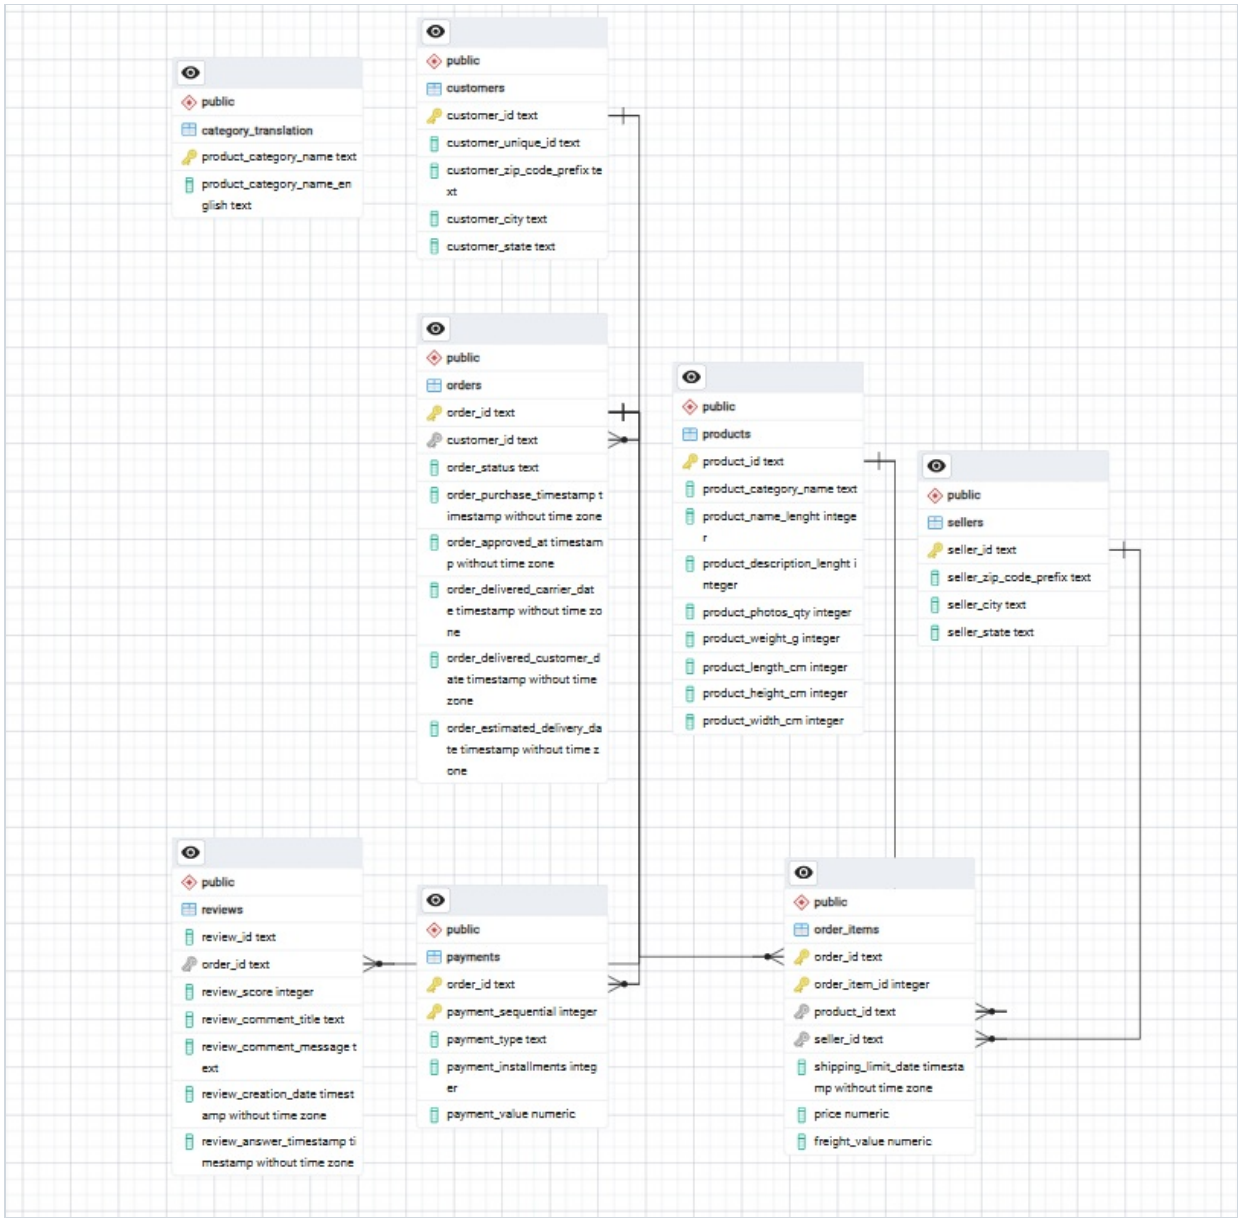
Стек

PostgreSQL, pgAdmin 4 (Query Tool, ERD Tool)

Структура репозитория

Файл	Содержание
`00_setup.sql`	Создание таблиц, загрузка CSV, первичные и внешние ключи
`01_data_quality.sql`	Проверки качества данных
`02_analysis.sql`	Аналитические запросы
`03_mart.sql`	Витрина данных для дашборда
`erd.png`	ER-диаграмма модели данных

Модель данных



Центральная сущность — заказ (`orders`). К нему относятся позиции (`order_items`), платежи (`payments`) и отзывы (`reviews`). Позиции ссылаются на товары (`products`) и продавцов (`sellers`), заказ — на клиента (`customers`).

Ключи добавлялись после загрузки данных, и это сразу помогло найти проблемы в данных (см. ниже).

Проверка качества данных (`01_data_quality.sql`)

- **Нарушение ссылочной целостности:** 2 категории товаров (`pc_gamer` и `portateis_cozinha_e_preparadores_de_alimentos`, 13 товаров) отсутствуют в справочнике переводов, поэтому внешний ключ `products → category_translation` создать нельзя.
- **Пропуски:** 610 товаров без категории, 8 заказов в статусе «доставлен» без даты доставки, 1 заказ без платежа.
- **Ловушка JOIN:** 2 961 заказ оплачен несколькими платежами. Прямое соединение позиций и платежей завышает выручку на 4,5%: 14 209 115 вместо 13 591 644. В анализе таблицы агрегируются до соединения.
- **Идентификатор клиента:** `customer_id` создаётся на каждый заказ (99 441 id), а реальных клиентов — 96 096 (`customer_unique_id`). Повторные покупки считаются по `customer_unique_id`.
- **Сверка сумм:** у 249 из 98 665 заказов (0,25%) стоимость товаров с доставкой расходится с суммой платежей больше чем на 1.

- **Отзывы:** у 547 заказов больше одного отзыва, поэтому оценка усредняется до уровня заказа.

Аналитика (`02_analysis.sql`)

Учитываются только доставленные заказы.

- **Динамика:** выручка, количество заказов, средний чек по месяцам и рост к прошлому месяцу (`LAG`) за январь 2017 — август 2018 (данные 2016 года неполные). Выручка выросла с 112 тыс. в январе 2017 до 0,8–1 млн в месяц в 2018 году. Пик — ноябрь 2017 (+52% к октябрю, вероятно, эффект Black Friday). Средний чек стабилен: 124–150.
- **Категории:** топ-10 по выручке (`RANK`). Лидер — health_beauty (9,3% выручки), за ней watches_gifts (8,8%) и bed_bath_table (7,7%). Топ-10 категорий дают около 62% выручки.
- **Повторные покупки:** только 3% клиентов (2 801 из 93 358) сделали больше одного заказа. Маркетплейс почти полностью держится на новых клиентах.

Главный вывод: задержка доставки и оценка клиента

Задержка относительно обещанной даты	Заказов	Средняя оценка	Доля оценок 1–2
Вовремя или раньше	89 443	4,29	9,2%
1–3 дня	1 852	3,29	32,2%
4–7 дней	1 748	2,11	67,6%
8–14 дней	1 446	1,67	80,1%
Более 14 дней	1 335	1,73	78,2%

Практический вывод: 93% заказов доставляются вовремя, но опоздание резко обрушивает оценку. Уже при опоздании на 1–3 дня доля негативных отзывов вырастает в 3,5 раза (с 9% до 32%), а при опоздании больше чем на 3 дня большинство оценок негативные (68–80%). Соблюдение обещанного срока доставки — один из ключевых факторов оценки. Бизнесу стоит контролировать опоздания (особенно у продавцов и регионов с наибольшими задержками) или закладывать более реалистичный срок доставки при оформлении заказа.

Витрина (`03_mart.sql`)

Представление `mart_order_items` объединяет заказы, позиции, клиентов, категории и отзывы. Одна строка — одна позиция доставленного заказа. Отзывы предварительно агрегируются до уровня заказа, чтобы не размножать строки. Корректность проверяется сверкой числа строк витрины с исходными данными.

Дальнейшие шаги

- Дашборд в Yandex DataLens на основе витрины.
- Анализ задержек доставки в разрезе штатов и продавцов.
- Когортный анализ удержания клиентов.